

Лабораторная работа № 2

Линейная регрессия. Градиентный спуск.

Знакомство с библиотеками Numpy, Matplotlib, Scikit-learn.

Цели лабораторной работы: Поиск модели линейной регрессии аналитически и с помощью различных вариантов градиентного спуска для минимизации среднеквадратической ошибки при нахождении модели линейной регрессии на языке Python.

Используемые библиотеки:

1. Pandas - [Руководство библиотеке Pandas на Python](#)
2. NumPy - [tools_numpy.ipynb - Colab](#)
3. Matplotlib – [Руководство по библиотеке Matplotlib на Python](#)
4. Scikitlearn.

С указанными библиотеками, а также базовыми возможностями языка Python можно в частности ознакомиться по книге:
Берман Кеннеди Основы Python для Data Science. — СПб.: Питер, 2023. — 272 с.

ТЕОРИЯ ДЛЯ ТОЧНОГО РЕШЕНИЯ

Одним из заданий лабораторной работы является поиск аналитического решения – минимума функции среднеквадратического отклонения.

В случае, когда вся выборка признаков записывается в виде матрицы:

$$X = \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_d^{(1)} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_1^{(l)} & x_2^{(l)} & \dots & x_d^{(l)} \end{pmatrix}, \text{ где } d - \text{число признаков, } l - \text{объем выборки}$$

а целевые значения - в виде вектора $Y = \begin{pmatrix} y_1 \\ \dots \\ y_l \end{pmatrix}$

Искомый вектор весов $\vec{W} = \begin{pmatrix} w_0 \\ \dots \\ w_d \end{pmatrix}$ соответствует минимальному

значению среднеквадратического отклонения $Q(W, X) = \frac{1}{l} \|XW - Y\|^2$

Данная задача имеет аналитическое решение

$$\vec{w} = (X^T X)^{-1} X^T Y, \quad (*)$$

которое предлагается найти для малого количества точек на листочке вручную, а для полной выборки – с помощью библиотеки NumPy.

При использовании библиотеки NumPy для нахождения транспонированной матрицы можно использовать оператор `.T`, а для нахождения произведения матриц `A` и `B` использовать оператор `A@B` или `A.dot(B)`. При этом матрицы должны быть созданы с помощью команды `numpy.array()`.

Например, матрица $\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ создается с помощью команды:
`numpy.array([[1,2],[3,4]])`.

Для нахождения обратной матрицы для матрицы `A` необходимо использовать команду `numpy.linalg.inv(A)`.

Пример кода (Python и matplotlib)

```
import numpy as np
import matplotlib.pyplot as plt

# определение функции
def func(x):
    return 0.1 * x**2 - np.sin(x) + 5.0


coord_x = np.arange(-5.0, 5.0, 0.1) # значения по оси абсцисс [-5; 5] с шагом 0.1
coord_y = func(coord_x) # значения функции по оси ординат
sz = len(coord_x) # количество значений функций (точек)

# Поиск точки максимума
max_y = coord_y[0]
arg_max = coord_x[0]
for i in range(sz):
    if(coord_y[i] > max_y):
        max_y = coord_y[i]
        arg_max = coord_x[i]
print("Точка максимума: (", arg_max, ", ", max_y, ")")

fig, ax = plt.subplots() # Создание окна и осей для графика
ax.grid(True) # отображение сетки на графике
ax.scatter(coord_x, coord_y, c='red')
ax.set_xlabel('Что по оси X')
ax.set_ylabel('Что по оси Y')
ax.set_title("Название графика")
ax.legend(['Смысл графика'])
plt.show()
```

Результат:

Точка максимума: (4.8999999999999965 , 8.383452612624305)



Задание и порядок работы

1. Создать Jupyter Notebook, в котором осуществить все действия, требуемые в задании лабораторной работы.
2. Используя библиотеку pandas, извлечь необходимые данные (столбцы независимой и зависимой переменной вашего варианта в нужном диапазоне, если указан) из набора данных, соответствующего вашему варианту.
3. Используя библиотеку matplotlib, изобразить выборку в виде отдельных точек в системе координат.
4. Выбрать 2 или 3 удаленных друг от друга по X точки выборки и самостоятельно найти параметры линейной регрессии $Y = w_0 + w_1X$ для этих точек аналитически, используя формулу (*) вручную на листочке. Построить в одной системе координат выбранные вами 2 или 3 точки и график линии регрессии с параметрами, вычисленными вручную.
5. Найти аналитически параметры линейной регрессии $Y = w_0 + w_1X$ по формуле (*) для всего объема выборки, используя библиотеку NumPy.
6. С помощью библиотеки matplotlib построить в одной системе координат точки вашего датасета и линии регрессии.
7. Решить задачу поиска оптимальных значений параметров w_0, w_1 линейной регрессии $Y = w_0 + w_1X$, минимизирующих функцию среднего квадратического отклонения с помощью:
 - а) пакетного градиентного спуска;

- б) стохастического градиентного спуска;
- в) мини-пакетного градиентного спуска.

В качестве ϵ взять 0,0001. В качестве шага взять 0,001.

8. С помощью библиотеки `matplotlib` построить в одной системе координат точки вашего датасета и линию регрессии, полученных с помощью трех вариаций градиентного спуска. В другой системе координат построить график функции $|Q^t - Q^{t-1}|$ в зависимости от номера итерации t . В третьей системе координат построить зависимость MSE (среднего квадратического отклонения) в зависимости от номера итерации t . Интерпретировать результаты.

9. С помощью библиотеки `scikit-learn` найти уравнение линейной регрессии.

10. В одной системе координат построить точки набора данных и полученное на шаге 7 уравнение линейной регрессии.

Индивидуальные задания

Номер варианта	Набор данных (датасет)	Независимая переменная (X)	Зависимая переменная (Y)
1	Salary.csv	Age (возраст)	Salary (зарплата)
2	mtcars.csv	cyl (число цилиндров)	hp (полная мощность)
3	Real estate.csv (записи с 1 по 50)	house age (возраст дома)	house price (цена дома)
4	wine.csv	Age (возраст)	Price(цена)
5	exam.csv (записи с 0 по 50)	Age (возраст)	mean_exam_points (средняя оценка за экзамен)
6	Fish (категория Bream)	Weight (вес)	Length (длина)
7	Fish (категория Roach)	Weight (вес)	Width (ширина)
8	Fish (категория Perch)	Width (ширина)	Weight (вес)

9	exam.csv (записи с 0 по 50)	lesson_price (цена за урок)	mean_exam_points (средняя оценка за экзамен)
10	exam.csv (записи с 100 по 150)	qualification (квалификация)	mean_exam_points (средняя оценка за экзамен)
11	Fish (категория Bream)	Length (длина)	Weight (вес)
12	Fish (категория Roach)	Weight (вес)	Height
13	Fish (категория Perch)	Height	Weight (вес)
14	exam.csv (записи с 0 по 50)	qualification	mean_exam_points
15	Fish (категория Roach)	Length 1	Height
16	Real estate.csv (записи с 100 по 150)	house age (возраст дома)	house price (цена дома)
17	Fish (категория Bream)	Height	Width
18	Fish (категория Roach)	Width (ширина)	Height
19	exam.csv (записи с 100 по 150)	Age (возраст)	mean_exam_points (средняя оценка за экзамен)
20	Fish (категория Perch)	Weight (вес)	Length (длина)
21	Fish (категория Bream)	Length (длина)	Weight (вес)
22	wine.csv	Year (год производства)	Price(цена)

23	Fish (категория Roach)	Width	Weight (вес)
24	Fish (категория Bream)	Length 1 (длина 1)	Height
25	exam.csv (записи с 100 по 150)	lesson_price (цена урока)	mean_exam_points (средняя оценка за экзамен)
26	Fish (категория Roach)	Height	Width (ширина)
27	Fish (категория Perch)	Width (ширина)	Height
28	Fish (категория Bream)	Weight (вес)	Length (длина)
29	Fish (категория Perch)	Length (длина)	Weight (вес)
30	Fish (категория Roach)	Weight (вес)	Width (ширина)